HAMi新特性，能力矩阵标准化

李 孟 轩

密 瓜 智 能 联 合 创 始 人
HAMi Maintainer

2025/12/27

CONTENT

目录

01 第一章：HAMi 简介

02 第二章：HAMi 新特性

03 第三章：HAMi 能力矩阵标准化

第一章：HAMi简介

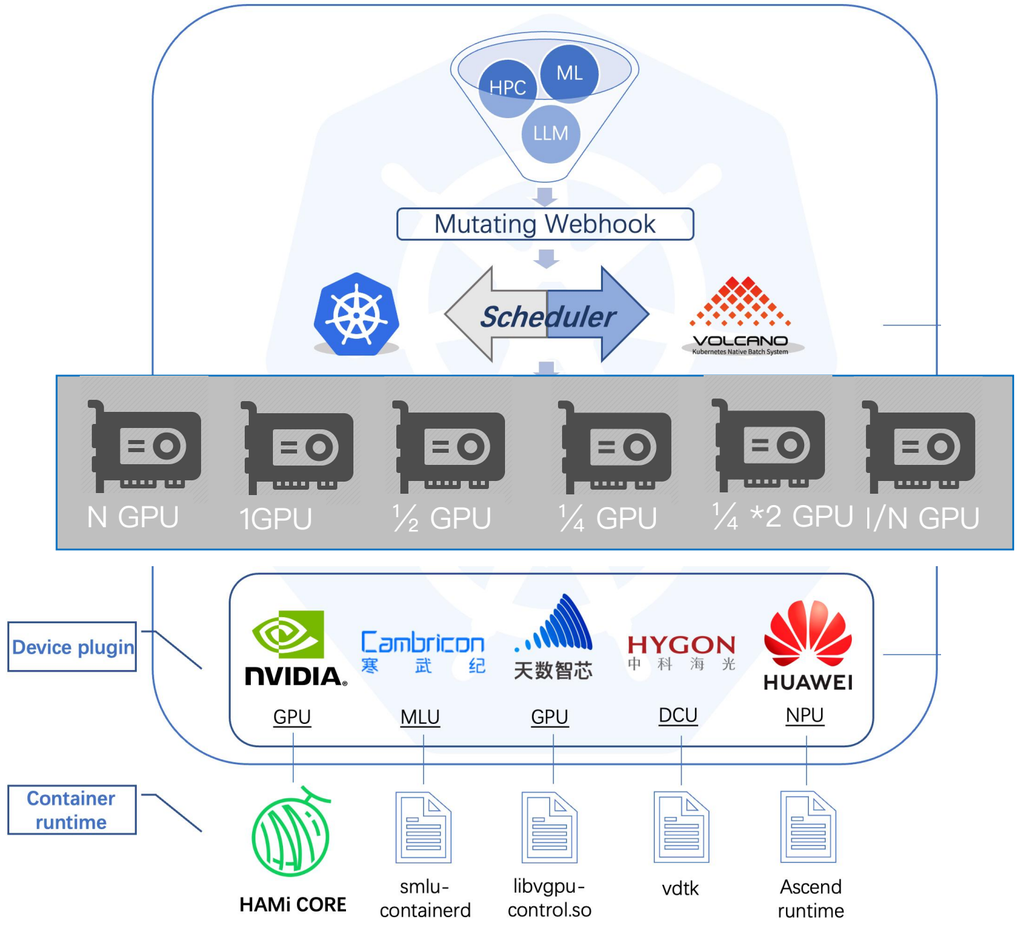

- 支持多种异构 AI 加速器芯片虚拟化能力，应用无侵入，0 成本使用
  - NVIDIA 强支持
    - 支持 MB 级别的虚拟化强隔离能力
    - 不同任务优先级抢占能力，优先保证高优先级任务
    - 显存超配
  - 其他国产芯片亦支持通过 HAMi 提供原厂 虚拟化能力(包括动态虚拟化)

第二章：HAMi 新特性

1. CDI支持

用户可以在.values.devicePlugin中，在以下字段配置CDI，当前仍然默认为环境变量的方式（envvar）

```
deviceListStrategy: "envvar"      # “cdi-annotations”为CDI模式
nvidiaHookPath: null              # 若开启CDI，这里需要配置宿主机nvidia-ctk的路径
nvidiaDriverRoot: null            # 若开启CDI，这里需要配置nvidia driver路径
gdrcopyEnabled: null
gdsEnabled: null
mofedEnabled: null
```

第二章：HAMi 新特性

2. Mock Device Plugin

许多HAMi的资源名并不会进行上报到node的**allocatible**与**capacity**中，用户可以按需部署**Mock Device Plugin**，其会根据集群内发现的设备**自动上报**

```
Capacity:
  cpu:                80
  ephemeral-storage:  921087820Ki
  hugepages-1Gi:      0
  hugepages-2Mi:      0
  memory:             791235772Ki
  nvidia.com/gpu:     20
  pods:               110
Allocatable:
  cpu:                79600m
  ephemeral-storage:  921087820Ki
  hugepages-1Gi:      0
  hugepages-2Mi:      0
  memory:             769189870398
  nvidia.com/gpu:     20
  pods:               110
```

第二章：HAMi 新特性

3. Ascend device plugin全面支持volcano调度器

与volcano vgpu类似：

- scheduler使用volcano
- device-plugin使用HAMi社区提供的ascend-device-plugin
- 容器层面使用Ascend-docker-runtime来限制显存/算力

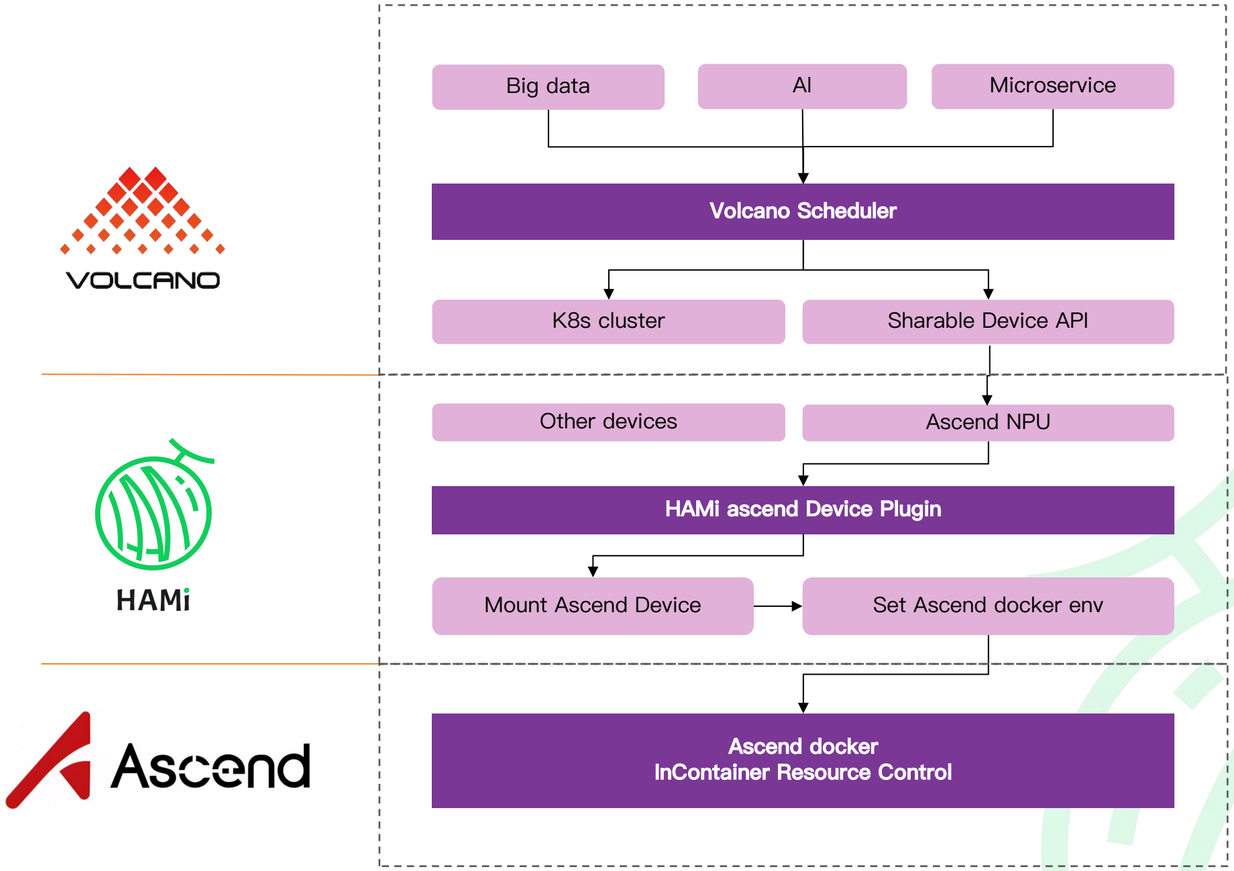

第二章：HAMi新特性

4. HAMi-DRA

原方案：webhook + scheduler + device-plugin + HAMi-core

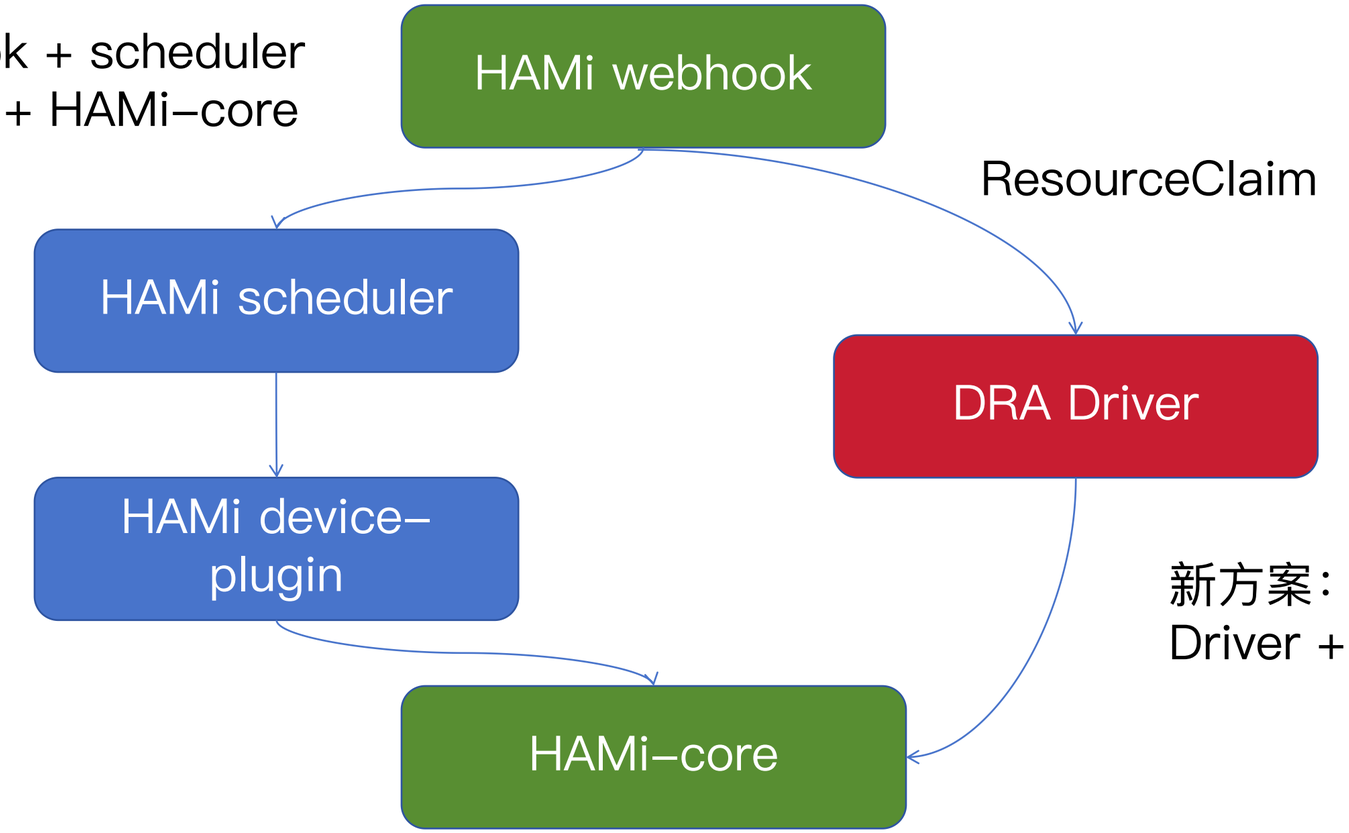

新方案：webhook + DRA Driver + HAMi-core

第三章：能力矩阵标准化

HAMi社区希望能与各个设备厂商一起共建开源生态

核心维度	子项	成熟度等级定义（L1–L4）
基础适配能力	Device–plugin 开源与维护完整性	L1：厂商闭源维护；L2：部分开源；L3：开源 + 社区维护；L4：开源 + 厂商&社区联合迭代
	GPU型号支持与资源上报完整性	L1：仅1类型号+基础信息；L2：2–3类型号+核心信息；L3：4+类型号+完整信息；L4：全型号覆盖
共享&虚拟化能力	虚拟化颗粒度	L1：无虚拟化；L2：固定模板；L3：中等颗粒度；L4：1%算力/1M显存细粒度
	显存/算力隔离强度	L1：无隔离；L2：软隔离；L3：显存强隔离；L4：显存+算力+带宽强隔离
调度能力	大模型网络拓扑感知调度（节点内的xxLink+NUMA亲和， 节点外的RDMA 网络拓朴）	L1：无网络拓扑信息上报；L2：上报但不优化；L3：基础亲和；L4：全栈联合优化
	指定UUID调度支持	L1：不支持；L2：实验性支持；L3：稳定支持；L4：支持任务绑定+热迁移
可观测性能力	容器级大模型指标监控完整性	L1：节点级监控；L2：容器级基础指标；L3：容器级实时指标；L4：容器级细粒度（含Kernel）
	调度关系可视化能力	L1：无关联；L2：文本日志；L3：静态图表；L4：动态拓扑图（GPU–容器–任务负载）
高阶资源优化能力	GPU超配支持（推理场景）	L1：不支持；L2：调度侧超配；L3：设备侧超配；L4：基于大模型 QPS 动态超配
	大模型优先级抢占与自动扩缩容	L1：不支持；L2：基础抢占；L3：抢占+固定扩缩容；L4：多维度动态扩缩容（QPS/显存）