vGPU推理集群的实践经验

贝壳找房 × HAMi：在千万级日请求量下，将GPU利用率提升3倍

算力平台开发工程师 王妮

贝壳找房

我们的舞台：支撑海量业务的统一算力平台

关于贝壳找房

国内领先的居住服务平台，业务覆盖二手房、新房、租赁等核心场景，服务规模覆盖全国多个城市。

AI平台角色

长期投入AI与云原生基础设施建设，通过统一算力平台为集团内部提供模型训练、在线推理与智能应用支撑，深度参与业务决策与效率优化。

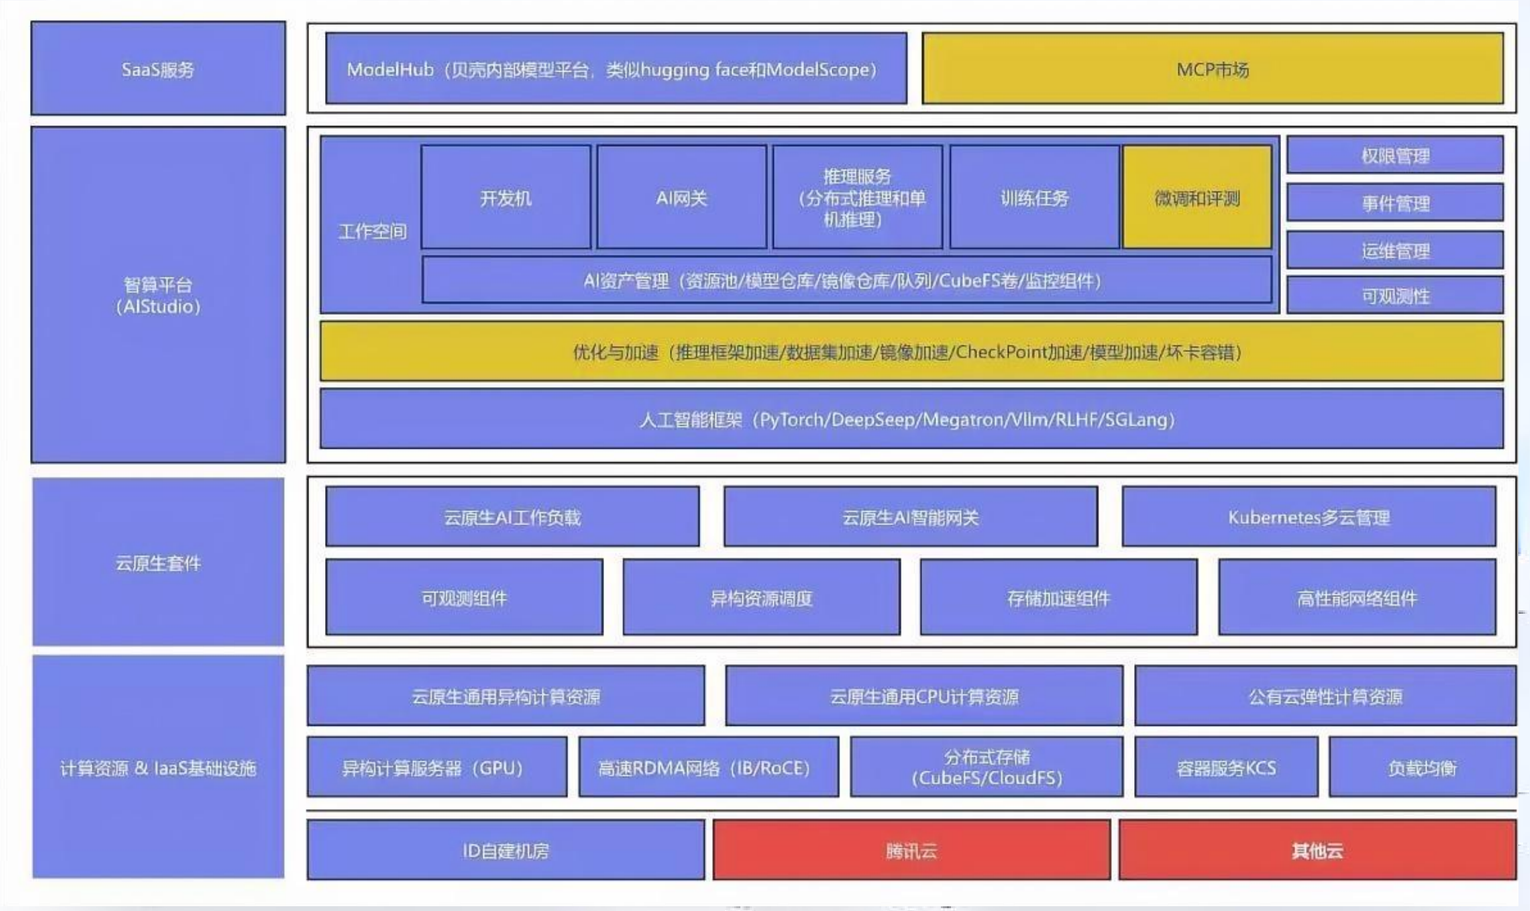

挑战：日益增长的推理需求与碎片化的资源消耗

推理请求规模

千万级

/ 日

模型形态

高度碎片化，包含大量TensorFlow小模型及32B以下语言模型。

资源需求

1–2GB

显存 / 单实例

核心困境：GPU越买越多，但利用率始终很低

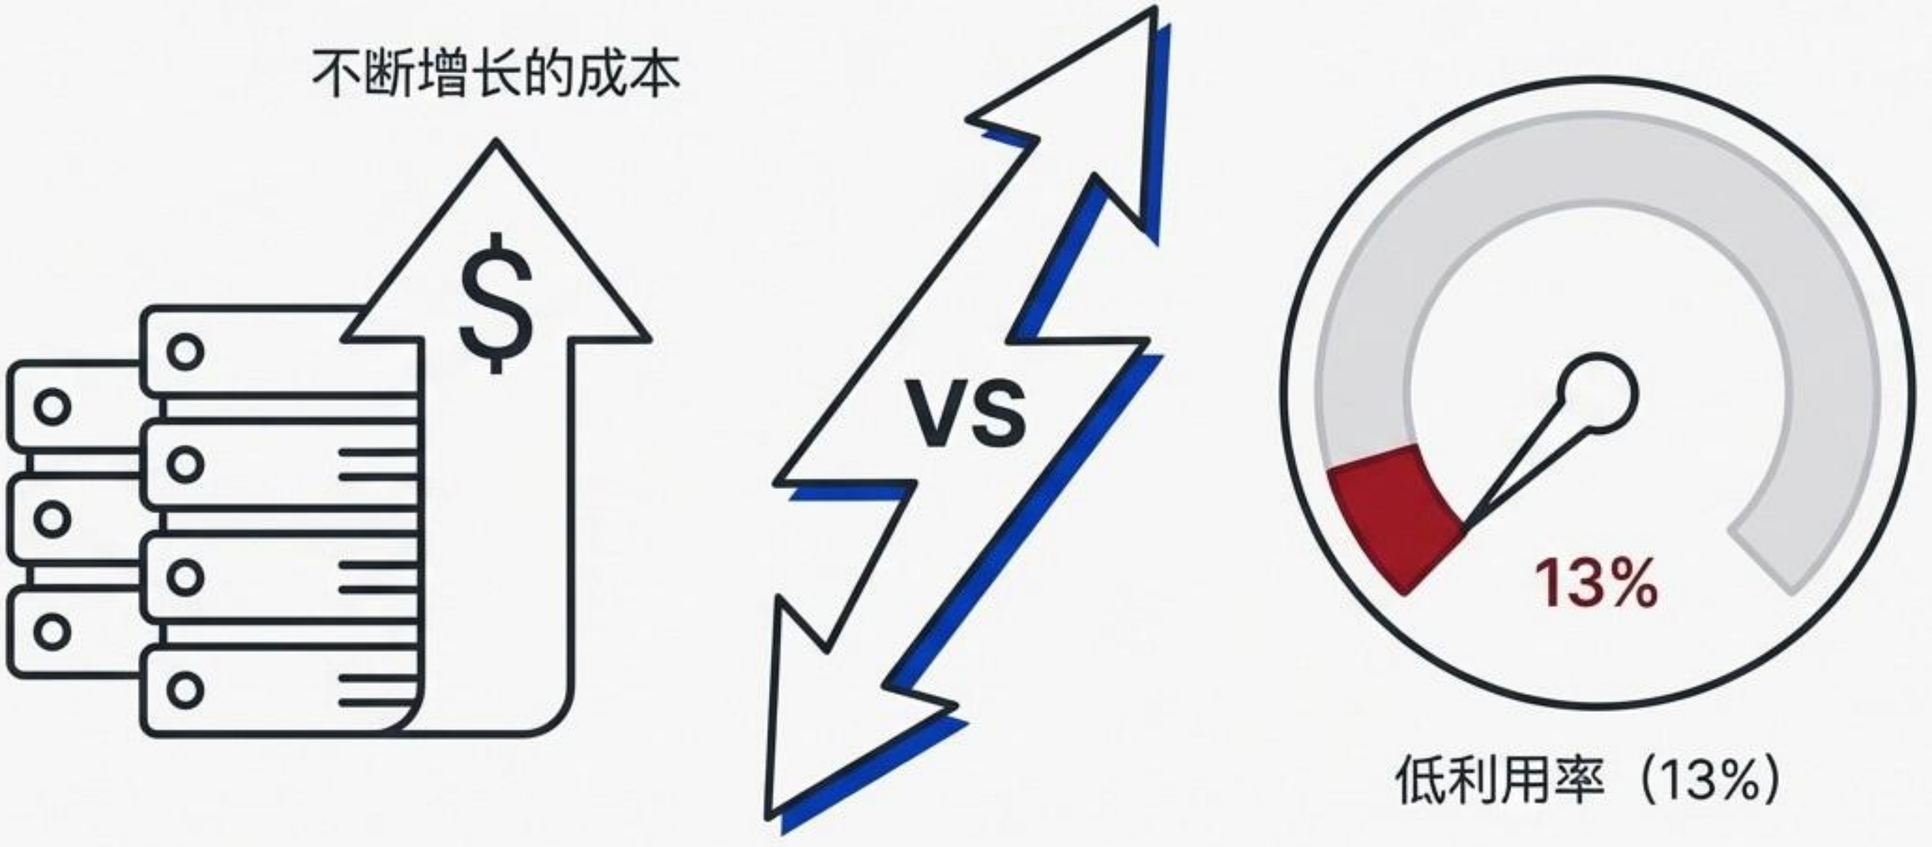

技术版图：跨云、多型号的千卡级GPU集群

GPU构成

- 以NVIDIA为主：H100 / V100 / 4090等，千卡规模，多型号并存。
- 未来规划：将引入更多异构算力。

集群形态

- 混合云部署：公有云（火山引擎、腾讯云）+ 私有云（自建集群）。
- 共5个Kubernetes v1.26+集群。

战略抉择：从基础设施层解决根本问题

❌ 再买卡：成本高，空闲更多。

❌ 改业务代码：成本高，风险大。

✔ 基础设施革新：通过调度与显存切切片解决问题。

我们的目标：无感、非侵入式的基础设施升级

不改应用形态

开发者继续以同样的方式申请和使用GPU资源。

不侵入业务代码

应用团队无需为适配新架构而重构代码。

用云原生方式解决

根本方案是调度与资源虚拟化，而非人工的应用层拼凑。

解决方案：针对不同负载的GPU差异化管理

大模型训练

目标： 追求极致性能
技术： 原生 NVIDIA device plugin
模式： 独占分配

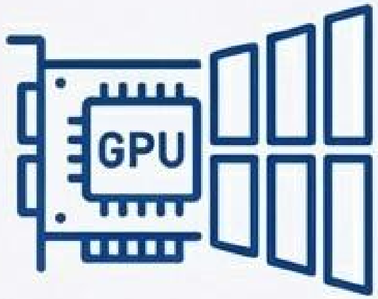

小模型推理

目标： 追求吞吐与利用率
技术： HAMi vGPU
模式： 显存切片与共享

技术架构：基于HAMi构建的vGPU推理集群

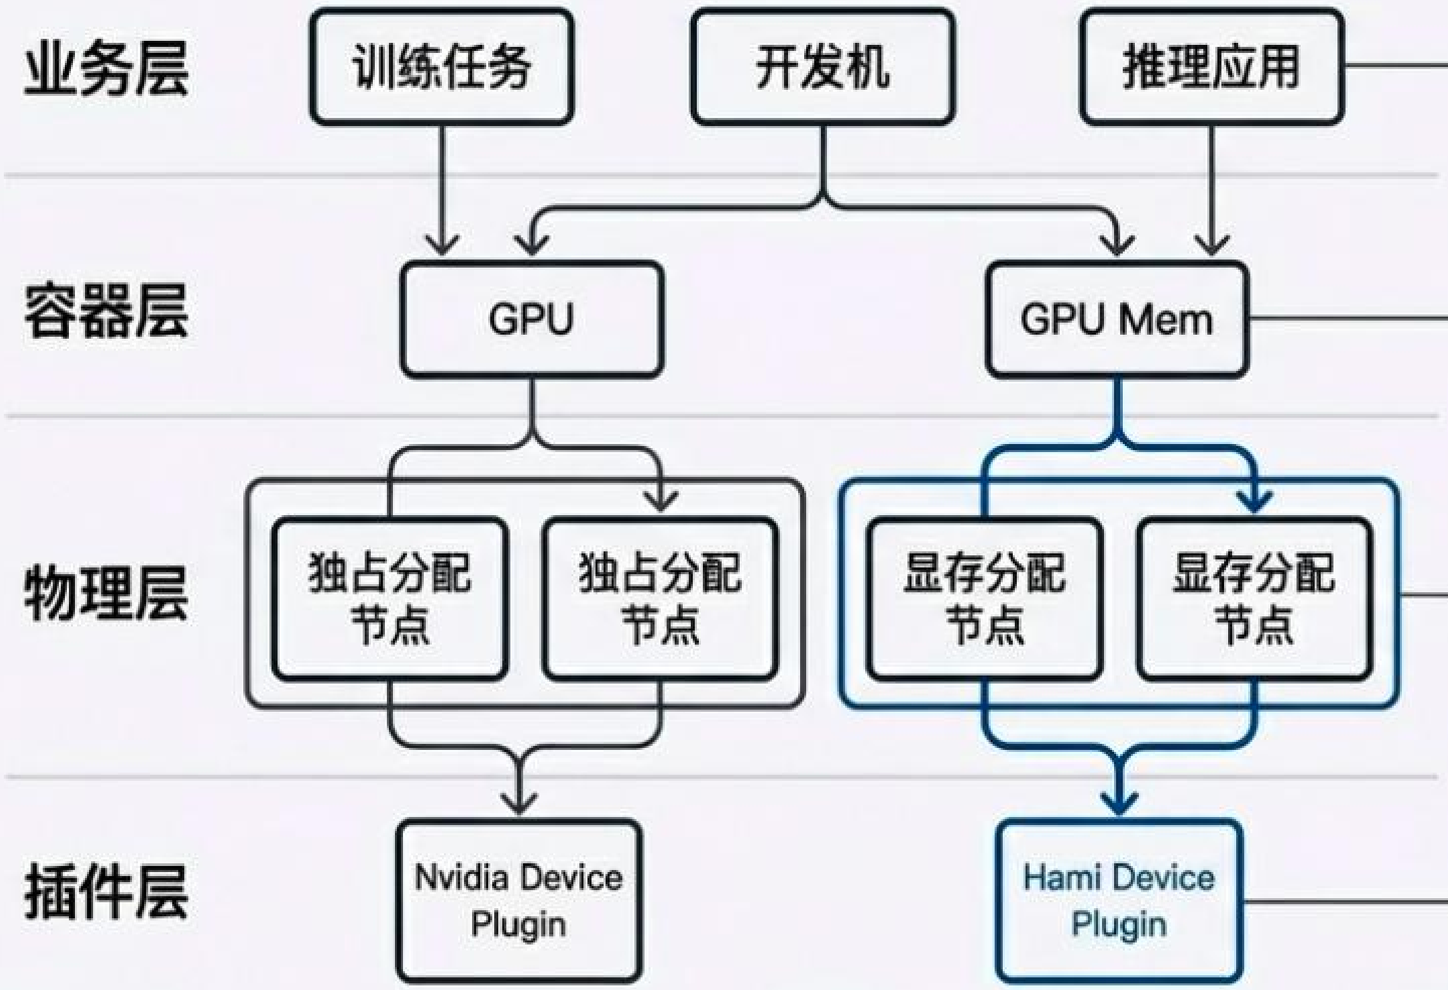

4. 业务层：训练任务与推理应用被清晰隔离。

3. 容器层：业务Pod通过申请`GPU Mem`被调度到相应节点。

1. 物理层：节点被划分为“独占分配节点”（用于训练）和“显存分配节点”（用于推理）。

2. 插件层：`Nvidia Device Plugin`和`Hami Device Plugin`并存，服务于不同类型的节点。

HAMi的核心作用：轻量级的显存虚拟化

核心能力

实现显存的硬性限制与隔离。未使用算力比例限制、未指定GPU型号等特性。

为什么“够用”

- 我们的推理场景瓶颈主要在**显存**，而非算力。
- 仅通过显存切片，就解决了80%的资源浪费问题。

> *“我们的平台是 built on top of HAMi。”*

工作流解析：一个推理Pod的生命周期

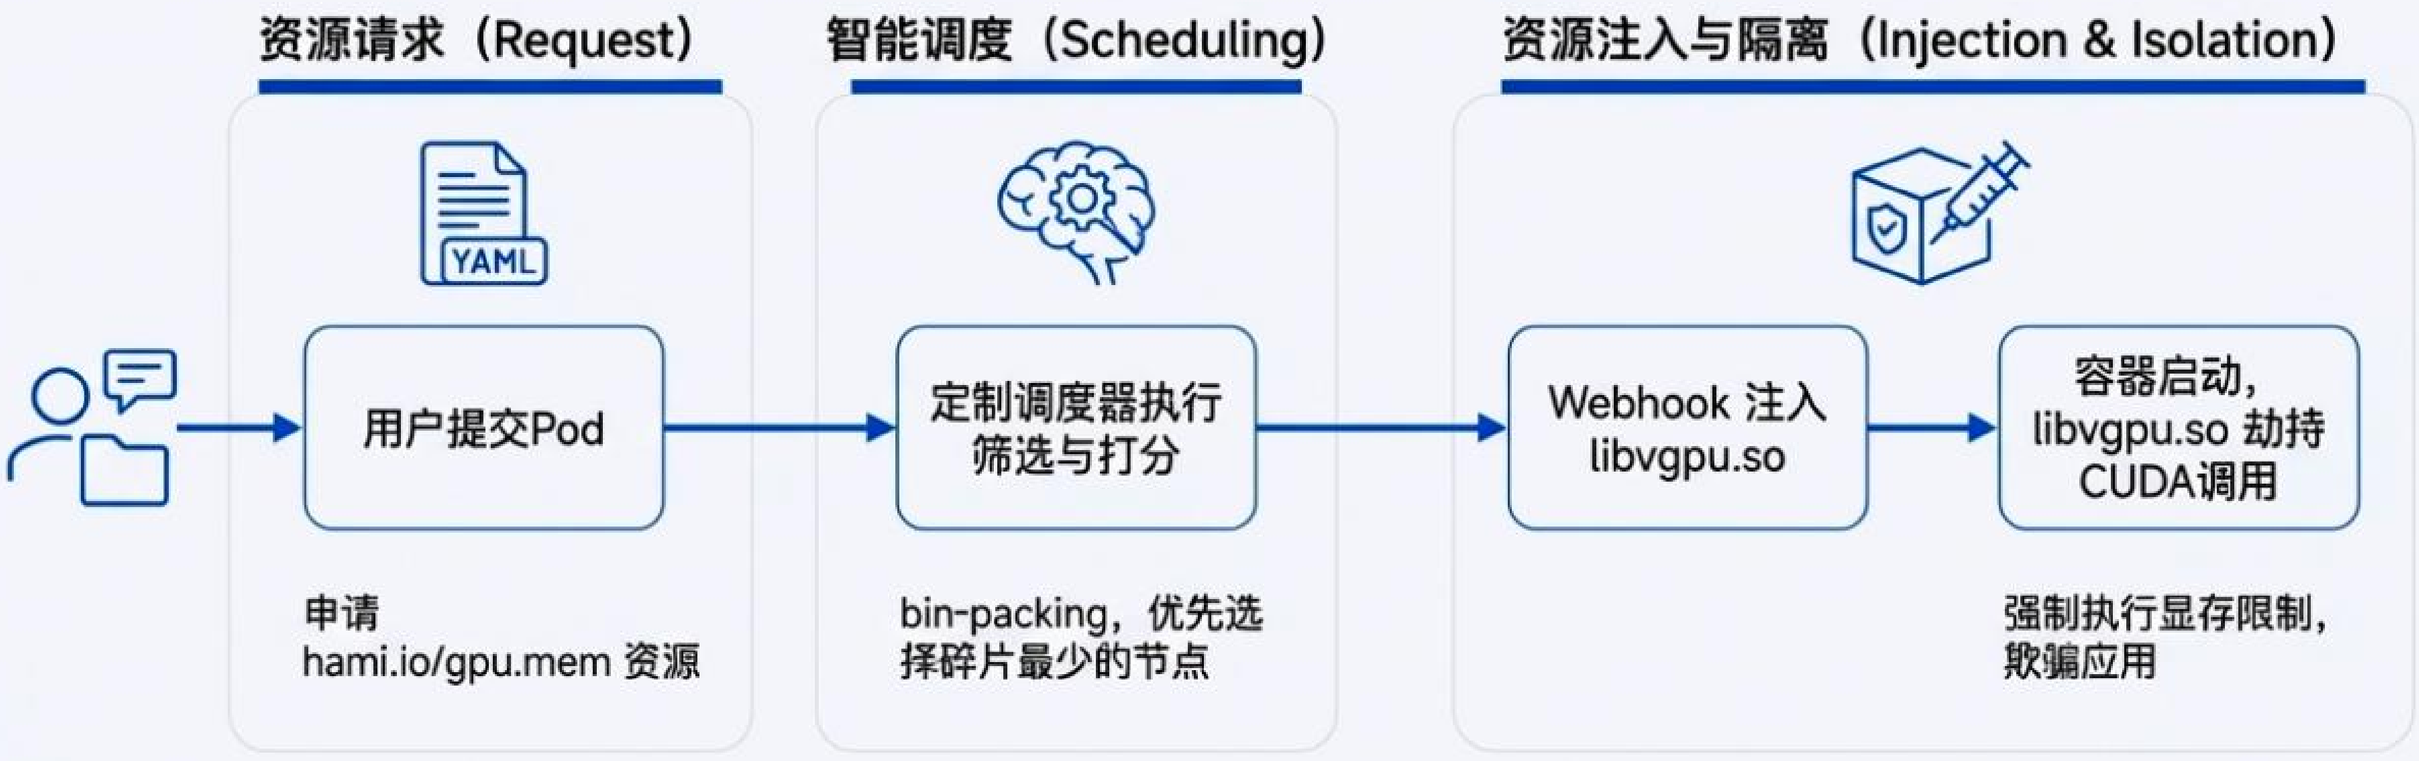

Pod视角

从应用开发者的角度看，体验与“独占GPU”几乎无异，但实际上是共享一张物理卡。

运行效果 I：千万级请求下的服务稳定性

推理延迟稳定

共享算力未引入明显的“邻居”干扰。

杜绝OOM重启

显存硬隔离从根本上避免了应用间因显存争抢导致的崩溃。

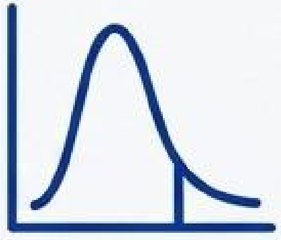

尾延迟可控

未观察到尾延迟被显著放大。

结论：推理服务稳定性得到显著提升。

运行效果 II：GPU整体利用率提升近3倍

在不改变应用形态的前提下，平稳支撑集团千万级/日推理请求。

我们的关键经验

1

推理场景，显存健优先于算力

对于碎片化的小模型推理，VRAM是真正的稀缺资源。

2

不要过早引入复杂的调度策略

从简开始，基础的bin-packing已能解决大部分碎片问题。

3

基础设施升级，业务可以“无感”

对用户完全透明是基础设施升级的最高标准。

未来规划与总结

未来规划

- 接入更多异构算力。
- 推理集群进一步规模化。
- 探索更精细的资源模型（如DRA）。

HAMi 帮我们解决了“怎么共享 GPU”，
而贝壳算力平台解决的是“怎么把共享用好”。