

天数智芯 GPU 上的 高性能推理部署实践

天数软件生态 · llm-d · PD 分离 · 集群部署



兼容

主流生态入口



优化

自研执行通信栈



集群

PD 可调谐



SLO

端到端可验收

叶成林

2026.09.04



上层保持兼容，下层把性能做到天数 GPU

兼容入口

OpenAI API · vLLM · Hugging Face

天数优化执行

ixFormer / IXInfer · ixDNN / ixBLAS

集群基础

IXCCL · IXLink · RDMA · 天数 GPU

可交付结果

首 Token

TTFT P99

流式稳定

TPOT P99

集群产出

吞吐 / GPU

最终口径


有效 Token

兼容降低迁移成本，自研栈兑现性能

一份声明驱动拓扑、路由、引擎和弹性



ix-ai-factory 推理服务架构



一份 YAML / CR

- Gateway / HTTPRoute
- Ilm-d EPP 选点
- Prefill / Decode 池
- 天数 GPU 节点
- 观测 → 弹性反馈

兼容 vLLM 生态，性能由自研软件栈兑现



兼容入口 → 天数执行

OpenAI API · vLLM

IxFormer / IXInfer

算子与矩阵库
ixDNN / ixBLAS


多卡通信
IXCCL

资源与拓扑信号进入同一控制面

- 1 **统一编排**
GPUClusterPolicy
- 2 **资源接入**
Device Plugin · DRA
- 3 **监控发现**
Exporter · FD
- 4 **拓扑调度**
ix-gpu-scheduler

HAMi: 小模型共享GPU

以 ix-gpu-operator 为统一编排入口，纳管运行底座、资源管理、监控观测、拓扑调度四层组件；
各层分工协作，构成一套完整的 Iluvatar GPU 云原生栈。



四层分工



运行底座层

ix-driver-manager 管理驱动生命周期,
ix-container-toolkit 提供 GPU 容器
运行时环境。



资源管理层 (两路线)

ix-device-plugin 走成熟的 Device
Plugin 路线;
ix-dra-driver 走下一代 DRA 路线,
两条路线并行演进。



监控观测层

ix-exporter 输出 GPU 指标,
ix-feature-discovery 发现节点 GPU
特征与拓扑。




拓扑调度层

ix-gpu-scheduler 做中心决策,
驱动 ix-device-plugin
按拓扑绑定 GPU。

联合放置 GPU 与 RDMA, IXCCL 承接集合通信



由 ix-gpu-scheduler 中心决策, 同时考虑 GPU 与 NIC 拓扑亲和, 通过 Pod Annotation 驱动下游绑定。



四大核心组件



架构总结: 中心决策统一协调 GPU 与 NIC 分配, 解决二者在 K8s 中“各自独立分配、互不感知拓扑”的行业痛点。

同一拓扑事实

北向 PCIe / NUMA
RDMA NIC
南向 IXLink / GPU 域

ix-gpu-scheduler
先证明放置可行

IXCCL
TP / PP 集合通信

设备分配只是开始，首个合格 Token 才算完成



任一阶段失败 → 整组不 Ready；半加载、半恢复或过期租约不计入容量

当前主路径

Device Plugin + Annotation


资源演进

DRA 属性化声明

按需分支

HAMi 小模型共享GPU

Ilm-d 负责角色化选点，天数执行栈负责把阶段跑快



控制面放置产能，llm-d 选点，天数节点执行 PD

入口层

Gateway → llm-d Proxy / EPP → Prefill Endpoint → Decode Endpoint

控制层

ix-ai-factory · ix-gpu-scheduler · HPA / KEDA / Planner

Prefill 天数 GPU 池

IXFormer / IXInfer · 计算优化

IXCCL: 池内 TP / PP 通信

输出 Sealed KV blocks

KV Transfer Adapter

RDMA / IXLink 能力

Decode 天数 GPU 池

IXFormer / IXInfer · KV / 带宽优化

IXCCL: 池内模型并行通信

按 TPOT 与 KV 压力扩容

瓶颈不同不代表分离一定更快

Prefill

计算密集 · 长输入并行

关注 TTFT、FLOPs、批处理和算子效率

天数优化：IxFormer / IXInfer + 算子库

Decode

HBM 带宽 · KV 容量敏感

关注 TPOT、活跃 KV、并发和队列

天数优化：运行时调度 + IXCCL 池内通信

收益

Prefill 计算节省 + Decode 排队节省

专用池、独立批处理、负载解耦

新增成本

KV 搬运 + 额外路由 + 远端排队

失败恢复、额外副本与传输占用

收益覆盖成本

并守住 SLO

才 Enable PD


短前缀 · 低并发 · 拥塞链路 → 优先合置

进行中

让新副本复用已就绪的权重、进程与 KV

ModelExpress


复用同构副本的权重与 JIT 制品



失败回退存储加载
半加载不计 Ready

Snapshot

跳过重复初始化、加载与预热



半恢复不得服务
天数运行时兼容性验证中

KVCR

块级驻留、卸载、恢复与 P2P

allocate → register → match

offload / restore → P2P move

旧块、跨域块、未密封块一律拒绝
KV 目录一致性仍在验证

兼容生态是入口，自研栈与 PD 闭环决定集群性能

01 · 兼容生态

vLLM / OpenAI

03 · 重点实践

llm-d + PD 闭环

02 · 自研优化

lxFormer · IXCCL

04 · 进行中

MX · Snapshot · KVCR

最终验收： TTFT · TPOT · Scale-to-First-Token · KV Transfer · 有效 Token

所有优化都回到端到端 SLO

Question?

