

智算平台的工程挑战与实践

从 GPU 资源到可用开发环境


资源抽象 · 多集群管理 · 工具注入 · GPU 虚拟化

SPEAKER

彭鹏

UCloud 高级研发工程师

UCloud



工程命题

平台如何把分散、异构、稀缺的 GPU，转化为开发者可以立即开始工作的环境？

我们为什么要建设智算平台

01 / INTERNAL TEAM

内部算法团队需求

需要快速获得稳定的
开发与训练环境

减少人工装机与环境等待

02 / SELF-BUILT CLUSTER

自建推理集群

需要统一管理集群容量、
任务与运行生命周期

提升 GPU 利用率与稳定性

03 / CUSTOMER GPU

客户自有 GPU

硬件已经采购，但缺少
可直接使用的管理平台

IaaS 太重，需要轻量方案

共同需求： 把已经拥有的 GPU，转化为可管理、可交付、可直接使用的算力服务

底层越异构，用户越期待简单




平台建设最终要交付三个结果




共同约束： 兼容性 · 隔离性 · 可维护性

智算平台总体架构




统一控制面管理异构 GPU 集群，交付开发环境与推理服务

围绕环境交付，我们重点解决五类工程问题




统一主线：一次开发环境交付请求，依次穿过五个工程断点

实例规格无法直接映射到 Kubernetes



业务层直接拼装底层配置，会让厂商逻辑散落在每一种工作负载中

用 Instance Spec 稳定上层，用适配层消化底层差异



工程边界： 用户仍选择型号、数量和镜像；平台统一的是内部契约与转换方式

上层稳定 → 中间转换 → 底层适配

多个独立集群，带来四类持续管理问题



多集群管理：完整编排还是轻量接入？

OPTION / KARMADA

能力完整的多集群编排

跨集群资源分发 · 策略调度

故障迁移 · 状态聚合

同时引入额外控制面与资源模型

ACTUAL / CURRENT SCOPE

当前场景足够收敛

一个任务只落在一个目标集群

不做跨集群分发、迁移与容灾

完整编排收益小于复杂度成本

DECISION / KUBECONFIG


平台控制面直接接入

复用 Kubernetes 原生 API 与权限体系

控制链路短，部署与排障更直接

能力边界与业务需求匹配

LIGHTWEIGHT MULTI-CLUSTER ACCESS



kubeconfig 作为敏感凭据管理：Secret 存储 · 最小权限 · 凭据轮换 · 访问审计

工具固化进镜像，升级成本会传导给每个环境




两个生命周期被绑定

算法依赖：追求稳定、可复现

平台工具：持续演进、频繁升级

强耦合 → 镜像膨胀 · 版本分叉 · 重复重建

在运行时装配工具，让算法镜像保持稳定



统一生命周期： 创建 → 健康检查 → 独立升级 → 回收

边界： 共享文件与网络接口必须显式

按需加载文件，让镜像无需完整下载即可启动

TRADITIONAL

启动前必须完成

完整下载

解压所有层

组装 rootfs

启动容器

准备阶段 · 一次生成

原始 OCI
镜像 Layer扫描压缩层
生成文件索引

INDEX ARTIFACT

文件路径 → 压缩数据区间
独立保存，原始 Layer 内容不变

运行时 · 先挂载后启动

01

获取元数据与索引

02

挂载远程 Layer

03

启动容器

04

访问文件时再读取

FILE READ PATH

文件访问

索引定位数据区间

Range 读取
所需数据片段

本地缓存

关键变化：容器启动不再等待全部镜像数据到达本地无有效索引 / 小 Layer
回退到常规完整拉取

先看部署场景，再选 GPU 隔离方案

SCENARIO A / PRIVATE

私有化智算

兼容 Kubernetes 资源体系

提高 GPU 资源利用率

控制私有化交付成本

K8S / UTILIZATION / DELIVERY

SCENARIO B / C-END

公有云 C 端场景

C 端 GPU 硬件能力受限

需补齐内核级资源控制

需补齐租户隔离边界

KERNEL / CONTROL / ISOLATION

SCENARIO C / B-END

公有云 B 端场景

保留设备直通性能

散卡组合与虚机绑定

管理 NVLink Fabric 生命周期

PASSTHROUGH / FABRIC / LIFECYCLE

硬件类型 × 部署形态 × 隔离要求 → 技术路径

三类部署场景，对应三种 GPU 隔离方案

PRIVATE AI PLATFORM

私有化智算**HAMi vGPU**

GPU 共享

显存与算力配额

提高集群资源利用率

PUBLIC CLOUD / C-END

公有云 C 端场景**内核级 vGPU**

内核层 GPU 资源切分

补齐 C 端 GPU 隔离能力

适配公有云多租户场景

PUBLIC CLOUD / B-END


公有云 B 端场景**QEMU 散卡透传**
共享 Fabric / PCIe-only

保留散卡直通性能


按多卡通信需求选路径

管理设备与 Fabric 生命周期

内核级 vGPU: VFIO + QEMU 设备虚拟化



方案一：保留共享 NVSwitch Fabric



HOW IT WORKS


Guest VM
只看到透传 GPU

Fabric Service
统一管理 NVSwitch
激活分区后再启动 VM

获得能力
1 / 2 / 4 / 8 卡 NVLink


工程边界
深度集成 Hypervisor 生命周期

方案二：禁用 NVLink, GPU 独立透传



工程边界： 失去 NVLink, 多卡通信回落到 PCIe; 模式切换通常需要重启节点

五个方案共同完成一次开发环境交付



从环境交付走向算力运营

当开发环境能够快速交付，瓶颈开始向模型、推理和资源利用迁移

01 / LOAD

权重加载加速

挑战 | 容器启动完成，不代表模型已经就绪

方向 | 权重分片 · 并行加载 · 远程挂载 · 本地缓存

让模型更快就绪

02 / COORDINATE

推理资源协同

挑战 | Prefill 与 Decode 的资源特征不同

方向 | PD 编排 · KV Cache 管理与复用 · 智能路由

调度整个推理过程

03 / REUSE

空闲 CPU 资源复用

挑战 | GPU 集群中的 CPU 容量长期闲置

方向 | Sandbox 承接隔离计算，统一容量与生命周期

GPU 跑模型，CPU 跑 Sandbox

04 / SELECT

异构算力智能调度

挑战 | 型号、代际和厂商能力差异持续扩大

方向 | 结合模型特征、性能画像与资源成本选型

让模型运行在合适的算力上

加载更快 · 推理更高效 · 闲置资源可复用 · 异构算力会选择

THANKS

感谢聆听

智算平台的工程挑战与实践

Q&A

QUESTIONS & DISCUSSION