

基于Volcano + HAMi-core 打造 K8s 异构 AI 加速算力底座

Dong Jiang, IFLYTEK, Volcano & Hami Member

个人简介

董江

容器技术布道者及实践者，Kubernetes、Prometheus、Volcano、Karmada、Hami、agentgateway等社区成员；Prometheus、agentgateway PMC 社区成员；Linux Foundation 开源导师、华为云 MVP/HCDE专家、腾讯云架构师技术联盟名人堂专家

KubeService Stack社区发起
个人博客
Github

<https://stack.kubeservice.cn/>
<https://kubeservice.cn/>
<https://github.com/dongjiang1989>

曾就职于 百度、阿里、滴滴、华为、贝壳、中国移动





汇报目录


Report to the directory

- 01 我们的场景
- 02 面临的挑战
- 03 核心技术方案
- 04 总体收益
- 05 加入社区

我们的舞台：支持多业务下的AI基础实施



AI Infrastructure




业务领域：教育、医疗、智慧城市、消费电子、智能驾驶、金融；

技术体系：融合语音模型、视觉模型、大语言模型等多项人工智能技术；

AI 基础设施：提供完整的 AI 能力底座，涵盖大数据处理、模型训练、模型服务部署、模型发布全链路；


我们面临的 AI 训练挑战：规模、复杂度、效率



挑战

- **资源碎片化**
大规模训练集群（数千 CPU/GPU 节点）
- **作业管理复杂度高**
遗留任务迁移（例如 Airflow、Spark Streaming）
- **工作负载多样化**
ETL、机器学习 / 深度学习模型训练、推理等
- **分布式训练复杂度**
单任务包含数百个参数服务器 (PS) 与工作节点 (Worker)
- **多任务编排**
异构 DAG 调度与数据传输

拥抱 Volcano&Hami-core: Kubernetes 统一解决方案



• 多引擎支持

基于 Volcano 实现统一的 Kubernetes 编排

• 智能资源调度

装箱调度、负载感知、拓扑感知、Gang 调度、DRF 资源公平调度

• DAG workflow编排

依托 JobFlow 与 JobTemplate 实现复杂业务流水线


• 多租户资源管理

基于队列的资源分配与公平性保障

• GPU虚拟化

依托Hami core兼顾算力隔离、细粒度资源切分

多租户资源管理：灵活分配 & 公平共享




资源队列管理

- **预分配队列**：为不同业务组织配置专属队列与共享队列
- **层级化配置**：支持队列最小 / 最大资源配额、权重配置，实现资源隔离与公平调度
- **弹性共享**：支持资源动态共享与自动回收

关键收益

- ✓ **组织灵活**：适配多租户架构
- ✓ **细粒度管控**：平衡共享与隔离
- ✓ **资源保障**：最小配额保障可用性

简化 workflows：高效编排复杂 AI 流水线



• DAG 编排实现

基于模板编排 (JobFlowTemplate / JobTemplate)

差分补丁执行, 支持动态更新

• 跨任务数据传输

对接 Kubernetes 存储卷

分布式存储优化

• 历史任务迁移


无缝集成 Airflow、Spark

统一管理平台

关键收益

- ✓ 统一 workflow 管控
- ✓ 去除数据传输开销
- ✓ 加速研发生命周期

优化分布式训练：面向大规模场景的智能调度



• Gang 成组调度

避免分布式作业出现资源饥饿问题

• 装箱调度算法

降低资源碎片，资源利用率提升 40%

• 真实负载感知调度

动态平衡资源公平性与隔离性

关键收益

- ✓ 保障关键作业资源供给
- ✓ 优化集群整体效率

业界开源方案：故障隔离 vs 显存隔离 vs 算力隔离

•不支持隔离但同 GPU 可以挂多 Pod（被大家称为“软隔离”）

- 阿里云 [gpushare-scheduler-extender](#)、[gpushare-device-plugin](#)
- [volcano GPU Sharing](#)
- [NVIDIA Time-Slicing](#)

•支持 cuda 层隔离的 vcuda

- 腾讯 tkestack [vcuda-controller\(cuda wrapper\)](#) , [gpu-manager\(device-plugin\)](#), [gpu-admission\(scheduler extender\)](#)
- Hami [hami-core](#)

•基于MPS方式

- 百度 [MPS+CUDA Hook](#) , 2.0 支持[用户态和内核态](#)两种方案
- 字节火山引擎

•驱动层实现隔离

- 阿里云 [cGPU](#)
- 腾讯云 [qGPU](#)

•GPU 池化

- [驱动科技GPU 池化](#)

•深度学习共享显存的GPU共享

- 蚂蚁人[深度学习](#)

GPU虚拟化：常见故障集合

一、故障传播：任务异常退出，导致MPS状态异常

业务GPU Pod异常崩溃，异常退出，导致在其他跑着同一个GPU（MPS是空分复用）容易引发硬件层面的 Fatal Exception，会导致此 GPU 上的其他进程一起退出。


修复：需要优雅退出 并 执行 `cudaDeviceSynchronize()`

二、显存不够时，还是调度到了共享GPU

GPU新驱动，当显存不够用时，可以系统内存借用一部分给显卡，Pod也启动了，但明显计算速度慢很多。

修复：系统设置中关闭共享内存

GPU虚拟化：兼顾算力隔离 & 细粒度资源切分



• 多维度 GPU 隔离

针对混合负载场景实现 GPU 显存与算力隔离

• GPU 细粒度切分

GPU 算力分片，实现资源灵活分配

• 多架构 GPU 兼容

兼容 T4、L20、A 系列、H 系列等多种异构架构

关键收益

- ✓ 提升训推混合场景下 GPU 利用率
- ✓ GPU workload 之间强隔离保障稳定性
- ✓ 无缝兼容 Kubernetes 生态、广泛适配多类型 GPU 硬件

总体收益

GPU资源利用率

40%



- 资源池化
- 装箱调度与组调度
- 弹性资源共享与回收
- 不同类型资源超分

故障恢复时间

70%



- 容器化
- 跨任务数据传输
- 统一 AI 任务工作流

资源干扰

50%



- 真实负载感知调度
- 预分配专属队列与共享队列



加入社区: iFlytek



Astron Agent



Skillhub



Astron RPA



MemFlyWhee
|



HarnessClaw



开源官网: <https://opensource.iflytek.com/>



github: <https://github.com/iflytek/>



加入社区: SparkLLM



Spark-X2.5-1.7B



Spark-X2.5-4B



官网: <https://xhtoken.ai>



github: <https://github.com/xhtoken/>

THANKS

Q&A